


# 1 Liczba wyświetleń a Like Rate

**Pytanie badawcze:** Jak zmieniał się Like Rate wraz ze wzrostem liczby wyświetleń filmu?



Rysunek 1: Like Rate a liczba wyświetleń w pełnej próbie

## 1.1 Wykres punktowy i krzywa LOWESS

Każda niebieska kropka na wykresie oznacza jeden film. Jej położenie na osi poziomej pokazuje liczbę wyświetleń, a położenie na osi pionowej — Like Rate wyrażony w procentach. Oś liczby wyświetleń ma skalę logarytmiczną, ponieważ wartości mieszczą się w bardzo szerokim zakresie: od kilku tysięcy do około miliona wyświetleń.

W obliczeniach wykorzystano zmienne:

$$x_i = \log_{10}(V_i), \quad y_i = 100L_i, \quad L_i = \frac{\text{Likes}_i}{V_i},$$

gdzie  $V_i$  oznacza liczbę wyświetleń  $i$ -tego filmu, a  $L_i$  jego Like Rate zapisany jako ułamek.

Aby dokładnie odtworzyć wyniki otrzymane wcześniej z widoku bazy danych, przed obliczeniami Like Rate zaokrąglono do czterech miejsc po przecinku. Odpowiada to dokładności 0,01 punktu procentowego.

Czerwona linia została wyznaczona metodą LOWESS. Nie zakłada ona z góry, że zależność ma być liniowa, kwadratowa albo wykładnicza. Zamiast dopasowywać jedną funkcję do całej próby, LOWESS dopasowuje wiele lokalnych prostych. Dla kolejnych miejsc na osi  $X$  wybiera najbliższe obserwacje, nadaje większą wagę punktom położonym bliżej, dopasowuje do nich

prostą i zapisuje jej przewidywaną wartość. Połączenie tych lokalnych przewidywań tworzy czerwoną krzywą.

## Jak działa LOWESS w tej analizie

### 1. Wybór badanego miejsca

Wybieramy punkt  $x_0$ , dla którego chcemy oszacować wygładzoną wartość Like Rate.

### 2. Obliczenie odległości

Dla każdej obserwacji obliczamy odległość od badanego miejsca:

$$d_i = |x_i - x_0|.$$

### 3. Wybór najbliższych obserwacji

Parametr `frac` ustawiono na 0,4854. Oznacza to, że do każdego lokalnego dopasowania wykorzystywane jest około

$$0,4854 \cdot 103 \approx 50$$

najbliższych filmów. Parametr `frac` steruje stopniem wygładzenia: mniejsza wartość daje bardziej elastyczną krzywą, a większa — gładszą.

### 4. Nadanie wag zależnych od odległości

Niech  $h$  oznacza największą odległość od  $x_0$  wśród obserwacji wybranych do lokalnego dopasowania. Definiujemy:

$$u_i = \frac{d_i}{h}.$$

Waga odległościowa ma postać funkcji trójsześciiennej:

$$w_i^{(d)} = \begin{cases} (1 - u_i^3)^3, & 0 \leq u_i < 1, \\ 0, & u_i \geq 1. \end{cases}$$

Im bliżej  $x_i$  znajduje się punktu  $x_0$ , tym większą otrzymuje wagę. Punkty leżące poza lokalnym sąsiedztwem mają wagę równą zero.

### 5. Dopasowanie lokalnej prostej

W wybranym sąsiedztwie dopasowujemy ważoną prostą:

$$\hat{y} = a + bx.$$

Oznaczmy przez  $\omega_i$  całkowitą wagę obserwacji. W pierwszym przejściu jest to waga odległościowa  $w_i^{(d)}$ . Średnie ważone wynoszą:

$$\bar{x}_\omega = \frac{\sum_i \omega_i x_i}{\sum_i \omega_i}, \quad \bar{y}_\omega = \frac{\sum_i \omega_i y_i}{\sum_i \omega_i}.$$

Współczynnik nachylenia lokalnej prostej jest równy:

$$b = \frac{\sum_i \omega_i (x_i - \bar{x}_\omega)(y_i - \bar{y}_\omega)}{\sum_i \omega_i (x_i - \bar{x}_\omega)^2},$$

natomiast wyraz wolny:

$$a = \bar{y}_\omega - b\bar{x}_\omega.$$

Wartość krzywej LOWESS w badanym miejscu wynosi więc:

$$\hat{y}(x_0) = a + bx_0.$$

## 6. Ograniczenie wpływu obserwacji odstających

W kodzie ustawiono `it=3`, dlatego po początkowym dopasowaniu wykonywane są trzy dodatkowe ważenia na podstawie reszt. Filmy o dużych resztach, czyli położone daleko od lokalnej prostej, otrzymują mniejszą wagę. Obserwacje z resztą większą niż sześciokrotność mediany bezwzględnych reszt mogą otrzymać wagę równą zeru. Dzięki temu pojedynczy nietypowy film ma mniejszy wpływ na przebieg czerwonej linii.

Cała procedura jest powtarzana dla kolejnych wartości  $x_0$ . Czerwona linia nie łączy więc bezpośrednio obserwowanych punktów, lecz przedstawia ciąg lokalnych oszacowań Like Rate.

### Odczyt krzywej

- przy kilku tysiącach wyświetleń wygładzony Like Rate wynosi około 5,7–6,0%
- w zakresie od około 7–10 tys. do 50–70 tys. wyświetleń widoczny jest wyraźny spadek Like Rate
- powyżej około 70–100 tys. wyświetleń krzywa wypłaszcza się w pobliżu 2,6–2,9%

LOWESS służy tutaj do opisanego kształtu zależności. Sam wykres nie pokazuje, że wzrost liczby wyświetleń powoduje spadek Like Rate.

## 1.2 Korelacja rang Spearmana

Korelację Spearmana zastosowano zamiast korelacji Pearsona, ponieważ liczba wyświetleń jest silnie asymetryczna, część filmów osiąga nietypowo duże zasięgi, a zależność widoczna na wykresie nie jest liniowa. Spearman mierzy siłę zależności monotonicznej na podstawie rang, a nie bezpośrednio na podstawie surowych wartości.

Niech  $R_i$  oznacza rangę liczby wyświetleń, a  $S_i$  rangę Like Rate. Współczynnik Spearmana jest korelacją Pearsona między tymi rangami:

$$\rho_S = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{\sqrt{\sum_{i=1}^n (R_i - \bar{R})^2} \sqrt{\sum_{i=1}^n (S_i - \bar{S})^2}}.$$

W pełnej próbie otrzymano:

$$\rho_S = -0,7212, \quad 95\% \text{ CI} = [-0,7863; -0,6333],$$

$$p = 8,5878 \cdot 10^{-18}, \quad n = 103.$$

Wartość  $\rho_S = -0,7212$  oznacza silną ujemną zależność rangową: filmy z większą liczbą wyświetleń miały zazwyczaj niższy Like Rate. Interpretujemy wartość bezwzględną współczynnika, czyli  $|\rho_S| = 0,7212$ , natomiast znak minus określa kierunek zależności.

Przedział ufności wyznaczono metodą bootstrapu. Dziesięć tysięcy razy losowano ze zwracaniem całe pary *liczba wyświetleń–Like Rate*, a następnie dla każdej wylosowanej próby ponownie obliczano  $\rho_S$ . Granice przedziału są percentylami 2,5% i 97,5% otrzymanych współczynników.

Cały przedział  $[-0,7863; -0,6333]$  znajduje się poniżej zera, co wspiera wniosek o ujemnym kierunku zależności. Bardzo mała wartość  $p$  oznacza, że przy hipotezie zerowej o braku monotonicznej zależności uzyskanie współczynnika co najmniej tak odległego od zera byłoby bardzo mało prawdopodobne. Wynik jest istotny statystycznie, ale nie dowodzi zależności przyczynowej.

### 1.3 Model elastyczności

Do ilościowego opisanie zależności zastosowano model log–log:

$$\ln(L_i) = \alpha + \beta \ln(V_i) + \varepsilon_i,$$

gdzie  $L_i$  oznacza Like Rate, a  $V_i$  liczbę wyświetleń. W pełnej próbie oszacowano:

$$\widehat{\ln(L_i)} = -1,1225 - 0,2139 \ln(V_i).$$

Otrzymano:

$$\hat{\beta} = -0,2139, \quad 95\% \text{ CI} = [-0,2750; -0,1529],$$

$$p = 3,6122 \cdot 10^{-10}, \quad R^2 = 0,4300, \quad n = 103.$$

W modelu log–log współczynnik  $\beta$  jest elastycznością. Wzrost liczby wyświetleń o 1% wiązał się przeciętnie ze spadkiem Like Rate o około 0,214%. Jest to zmiana względna Like Rate, a nie spadek o 0,214 punktu procentowego.


Dokładną względną zmianę Like Rate przy  $k$ -krotnym wzroście liczby wyświetleń obliczamy ze wzoru:

$$100 \left( k^{\hat{\beta}} - 1 \right) \%.$$

Dla pełnej próby wzrost liczby wyświetleń o 10% odpowiadał przeciętnemu spadkowi Like Rate o około 2,02%, a podwojenie liczby wyświetleń — spadkowi o około 13,79%.

Cały przedział ufności dla  $\beta$  znajduje się poniżej zera. Model z jedną zmienną objaśnia około 43,0% zróżnicowania logarytmu Like Rate. Zastosowano odporne błędy standardowe HC3. Wyrazu wolnego nie interpretujemy praktycznie, ponieważ odpowiada on filmowi z jednym wyświetleniem, czyli sytuacji znajdującej się poza użytecznym zakresem danych.

## 2 Analiza odporności po wyłączeniu TOP 7



Rysunek 2: Like Rate a liczba wyświetleń po wyłączeniu siedmiu filmów o największym zasięgu

Siedem filmów o największej liczbie wyświetleń wyłączono wyłącznie w analizie odporności. Nie oznacza to uznania ich za błędne obserwacje. Celem było sprawdzenie, czy wynik pełnej próby nie jest w całości napędzany przez filmy o największym zasięgu. Po ich wyłączeniu pozostało:

$$n = 96.$$

W zakresie wspólnym dla obu wykresów kształt krzywej LOWESS pozostał podobny. Nadal widoczny jest niewielki początkowy wzrost, następnie silny spadek i późniejsze łagodzenie spadku. Oznacza to, że ujemna zależność nie wynika wyłącznie z siedmiu filmów o

największej liczbie wyświetleń. Jednocześnie to właśnie te filmy tworzą prawy, viralowy fragment pełnego wykresu, na którym krzywa wyraźnie się wypłaszcza.

## 2.1 Korelacja rang Spearmana

Po wyłączeniu TOP 7 otrzymano:

$$\rho_S = -0,6993, \quad 95\% \text{ CI} = [-0,7744; -0,5996],$$

$$p = 2,2811 \cdot 10^{-15}, \quad n = 96.$$

Zmiana oszacowania wyniosła:

$$-0,6993 - (-0,7212) = 0,0219.$$

Współczynnik stał się więc nieznacznie mniej ujemny, ale zależność nadal jest silna. Przedziały ufności obu oszacowań w dużym stopniu się pokrywają. Samo nakładanie się przedziałów nie jest jednak formalnym testem różnicy między korelacjami, dlatego na tej podstawie nie stwierdzamy ani istotności, ani nieistotności zmiany.

## 2.2 Model elastyczności

Po wyłączeniu TOP 7 oszacowano:

$$\widehat{\ln(L_i)} = -0,3472 - 0,2987 \ln(V_i).$$

Otrzymano:

$$\hat{\beta} = -0,2987, \quad 95\% \text{ CI} = [-0,3731; -0,2244],$$

$$p = 3,5728 \cdot 10^{-12}, \quad R^2 = 0,4750, \quad n = 96.$$

Wzrost liczby wyświetleń o 1% wiązał się przeciętnie ze spadkiem Like Rate o około 0,299%. Wzrost liczby wyświetleń o 10% odpowiadał spadkowi Like Rate o około 2,81%, a podwojenie liczby wyświetleń — spadkowi o około 18,70%.

Dla pełnej próby otrzymano  $\hat{\beta}_{\text{pełna}} = -0,2139$ , natomiast po wyłączeniu TOP 7:

$$\hat{\beta}_{\text{bez TOP 7}} = -0,2987.$$

Różnica oszacowań wyniosła:

$$-0,2987 - (-0,2139) = -0,0848.$$

Oszacowana zależność stała się bardziej ujemna. Jest to zgodne z krzywą LOWESS: w typowym zakresie zasięgów Like Rate wyraźnie spadał, natomiast w prawym, viralowym fragmencie pełnej próby spadek ulegał wypłaszczeniu. Nie oznacza to jednak, że różnica

między współczynnikami  $-0,2139$  i  $-0,2987$  jest statystycznie istotna. Do takiego wniosku potrzebny byłby osobny test.

Model bez TOP 7 wyjaśnia około 47,5% zróżnicowania logarytmu Like Rate.

## 2.3 Porównanie wyników

| Miara                        | Pełna próba | Bez TOP 7 |
|------------------------------|-------------|-----------|
| Liczba filmów $n$            | 103         | 96        |
| Korelacja Spearmana $\rho_S$ | $-0,7212$   | $-0,6993$ |
| Elastyczność $\hat{\beta}$   | $-0,2139$   | $-0,2987$ |
| $R^2$ modelu log-log         | 0,4300      | 0,4750    |

Analiza odporności prowadzi do dwóch wniosków. Po pierwsze, ujemna zależność rangowa pozostaje silna po wyłączeniu największych filmów. Po drugie, oszacowana elastyczność staje się bardziej ujemna, ponieważ usunięto fragment danych, w którym spadek Like Rate wcześniej się wypłaszczał. W żadnym z modeli nie należy interpretować tej zależności jako dowodu, że większa liczba wyświetleń sama w sobie powoduje niższy Like Rate.